

# Методы машинного обучения для функционального картирования мозга

Арина Чумаченко

Московский физико-технический институт,  
Сколковский институт науки и технологий

*Научный руководитель:* Шараев Максим Геннадьевич

2024

# Цель исследования

## Проблема

Снижение индексности данных о функциональной связности в состоянии покоя при построении карт активации.

## Решение

Сегментация (картирование) функциональных областей fMRI снимков мозга

# Постановка задачи

## Датасет:

### Human Connectome Project

≈ 1200 здоровых индивидов с данными МРТ в состоянии покоя  
4D (3D данные, зависящие от времени)  $1,5 \times 10^6$ -мерные МРТ-измерения в несколько секунд

## Output:

$\mathbf{F}_i$  — модель, извлекающая объекты

$y_i$  — истинная активация, где  $i$  соответствует индивиду  $i$ .

Для каждого объекта определим  $\beta_i$  с помощью минимизации MSE:

$$\mathbf{y}_i = \mathbf{F}_i \beta_i$$

Среднее  $\beta_i$  по всем  $N$  обучаемым объектам:

$$\beta = \frac{1}{N} \sum_{i=1}^N \beta_i$$

## Анализ независимых компонент

Может быть представлен как "problem of cocktail party".

В основном применяется к данным fMRI:

$$\mathbf{x} = \mathbf{A}\mathbf{s},$$

где  $\mathbf{x}$  – наблюдаемые данные ( $N \times 1$ ),

$\mathbf{s}$  – смесь исходного вектора ( $d \times 1$ ,  $N \geq d$ ),

$\mathbf{A}$  – матрица смешивания ( $N \times d$ ).

**Цель ICA:** найти матрицу  $\mathbf{W}$  ( $d \times N$ ). Output:

$$\mathbf{y} = \mathbf{W}\mathbf{x}$$

предоставляет оценки всех сигналов  $d$  источников.

# Spatially constrained ICA fMRI

Максимизация функции контрастности стандартного алгоритма blind ICA:

$$\begin{aligned} & \text{maximize } J(\mathbf{y}) \\ & \text{s.t. } \mathbf{g}(\mathbf{y} : \mathbf{W}) \leq 0; \mathbf{h}(\mathbf{y} : \mathbf{W}) = 0 \end{aligned}$$

Стандартный blind ICA алгоритм:

$$J(\mathbf{y}) = \sum_{i=1}^L J(y_i), \quad J(y_i) \approx \rho [E\{G(y_i)\} - E\{G(v)\}]^2$$

Предложенный подход

$$\begin{aligned} & \text{maximize } J(\mathbf{y}) = \sum_{i=1}^L J(y_i), \\ & \text{s.t. } \mathbf{g}(\mathbf{y} : \mathbf{W}) \leq 0 \end{aligned}$$

# Spatially constrained ICA fMRI

Алгоритм с фиксированной точкой:

$$\mathbf{W}(k) = \langle \bar{\rho} \rangle E \{ G'_y(\mathbf{W}(k-1)\mathbf{x})\mathbf{x}^T \} - \frac{1}{2} \langle \bar{\mu} \rangle E \{ g'_y(\mathbf{y} : \mathbf{W}(k-1))\mathbf{x}^T \}$$

$$\bar{\rho} = E\{G(\mathbf{y})\} - E\{G(\mathbf{v})\}$$

$$\bar{\mu}(k+1) = \max\{\mathbf{0}, \bar{\mu}(k) + \langle \bar{\gamma} \rangle g(\mathbf{y} : \mathbf{W})\}$$

$$\mathbf{W} = (\mathbf{W}\mathbf{W}^T)^{-1/2}\mathbf{W}$$

## Resting state fMRI mapping

Задача: "baseline" + "sparse"

**Baseline:**

$$\hat{\beta}_j = \arg \min_{\beta_j \in \mathbb{R}} \|\mathbf{y}_j - \mathbf{X}_j \beta_j\|_2^2$$

**Sparse:**

$\tilde{\mathbf{X}}_S^i = [\mathbf{x}_1^i, \dots, \mathbf{x}_N^i]^T$ , где  $\mathbf{x}_j^i$  –  $i$ -ая карта вариаций состояния покоя объекта  $j$ .

Уменьшим размерность, используя ICA:  $\tilde{\mathbf{X}}_S^i = \mathbf{A}_S^i \mathbf{S}^i$ ,  $i = 1, \dots, k$ ,

$\mathbf{A}_S^i$  –  $N \times d$  матрица смешивания,

$\mathbf{S}^i$  – множество  $d$  независимых компонент, представляющих общие пространственные вариации по всем объектам обучения  $S$ .

$\mathbf{A}_S^{\text{rest}} = [\mathbf{A}_S^1, \mathbf{A}_S^2, \dots, \mathbf{A}_S^k]$  –  $N \times dk$  матрица.

Найдём  $\mathbf{W}$  (регуляризованная регрессия в ICA-reduced  $\mathbf{A}_S^{\text{task}} (N \times p)$ ):

$$\hat{\mathbf{W}} = \arg \min_{\mathbf{W}=[\mathbf{w}_1, \dots, \mathbf{w}_p] \in \mathbb{R}^{dk \times p}} \left\{ \|\mathbf{A}_S^{\text{task}} - \mathbf{A}_S^{\text{rest}} \mathbf{W}\|_F^2 + \sum_{i=1}^p \lambda_i \|\mathbf{w}_i\|_1 \right\} \quad (1)$$

или на исходных картах задач  $\mathbf{Y}_S = \mathbf{A}_S^{\text{task}} \mathbf{S}^{\text{task}} (N \times V)$ :

$$\hat{\mathbf{W}} = \arg \min_{\mathbf{W}=[\mathbf{w}_1, \dots, \mathbf{w}_V] \in \mathbb{R}^{dk \times V}} \left\{ \|\mathbf{Y}_S - \mathbf{A}_S^{\text{rest}} \mathbf{W}\|_F^2 + \sum_{i=1}^V \lambda_i \|\mathbf{w}_i\|_1 \right\} \quad (2)$$

## Resting state fMRI mapping

Хотим решить проблему линейной регрессии ( $\mathcal{T}$  - тестовая выборка,  $n = |\mathcal{T}|$ ):

$$\hat{\mathbf{A}}_{\mathcal{T}}^i = \arg \min_{\mathbf{A}_{\mathcal{T}}^i \in \mathbb{R}^{n \times d}} \|\hat{\mathbf{X}}_{\mathcal{T}}^i - \mathbf{A}_{\mathcal{T}}^i \mathbf{S}^i\|_F^2$$

Предсказания для набора невидимых объектов  $\mathcal{T}$ :

$$\hat{\mathbf{Y}}_{\mathcal{T}} = \hat{\mathbf{A}}_{\mathcal{T}}^{\text{rest}} \hat{\mathbf{W}} \mathbf{S}^{\text{task}}$$

если  $\hat{\mathbf{W}}$  решается с помощью (1) или

$$\hat{\mathbf{Y}}_{\mathcal{T}} = \hat{\mathbf{A}}_{\mathcal{T}}^{\text{rest}} \hat{\mathbf{W}}$$

если  $\hat{\mathbf{W}}$  решается с помощью (2).

### The ensemble model:

Линейная регрессия:

$$\hat{\theta}_i^{(1)} \hat{\theta}_i^{(2)} = \arg \min_{\theta_i^{(1)}, \theta_i^{(2)}} \left\| \mathbf{y}_{\cdot, i}^S - \theta_i^{(1)} \hat{\mathbf{y}}_{\cdot, i}^{\text{baseline}} - \theta_i^{(2)} \hat{\mathbf{y}}_{\cdot, i}^{\text{sparse}} \right\|_2^2$$



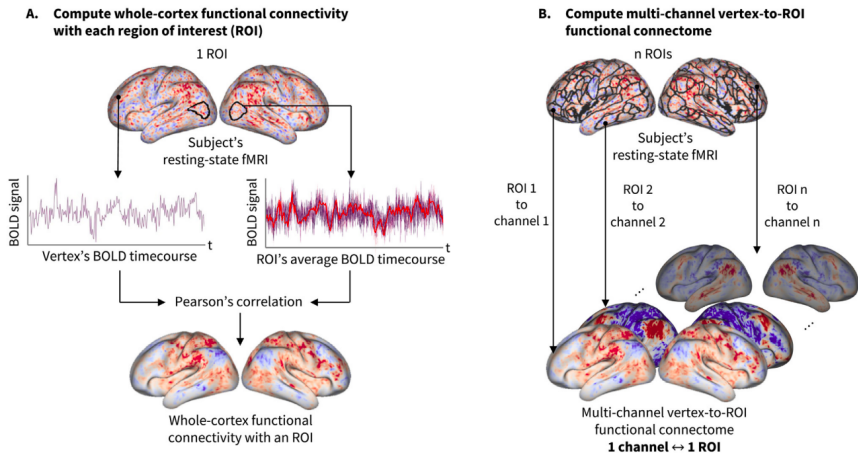
## Ключевые слова:

- ▶ Функциональный коннектом
- ▶ Вертекс (vertex)
- ▶ Парсель (parcel)
- ▶ Интересующий регион (ROI, region of interest)
- ▶ Карта контрастности

## Vertex-to-ROI:

$r_{ij}$  – функциональная связность между  $i$ -ой вершиной поверхности и  $j$ -ым интересующим регионом, вычисленная как коэффициент корреляции Пирсона  $corr(.)$  между временными рядами  $\mathbf{t}_i$  rsfMRI в  $i$ -й вершине и средним значением временных рядов  $\bar{\mathbf{t}}_j$  для  $j$ -го интересующего региона:

$$r_{ij} = corr(\mathbf{t}_i, \bar{\mathbf{t}}_j)$$



**Fig.1.** Многоканальные функциональные коннекты vertex-to-ROI, вычисленные на основе rsfMRI

# Метод

Модель основана на архитектуре UNet.

Входная и выходная поверхности представляют собой шаблоны fs\_LR с 32k вершинами на каждое полушарие мозга.

Output: многоканальная сетка, каждый канал соответствует контрасту для одной задачи.

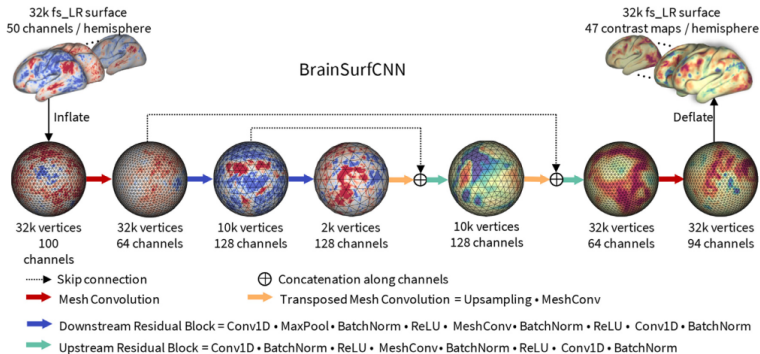


Fig.2. Модель BrainSurfCNN

## Метод (baseline)

### Линейная регрессия:

$$\mathbf{y}_i^k = \mathbf{X}_i^k \beta_i^k$$

$\mathbf{y}_i^k$  – патерн активации ( $n_k \times 1$ , где  $n_k$  – количество вертексов в  $k$ -ом парселе в обоих полушариях мозга),

$\mathbf{X}_i^k$  – извлечённые объекты ( $n_k \times M$ , функциональная матрица связности, где каждый элемент был вычислен как корреляция Пирсона между вертексом и средним временных рядов каждого из  $M$  интересующих регионов),

$\beta_i^k$  – регрессор  $k$ -го парселя для  $i$ -го индивида ( $M \times 1$ ).

### Предсказанный патерн активации:

$$\hat{\mathbf{y}}_{\text{test}}^k = \mathbf{X}_{\text{test}}^k \bar{\beta}^k = \mathbf{X}_{\text{test}}^k \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \beta_i^k = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} \mathbf{X}_{\text{test}}^k \beta_i^k$$

$\bar{\beta}^k$  – усреднённые веса моделей линейной регрессии для  $k$ -го парселя, вычисленного по  $N_{\text{train}}$  объектам обучения.

## Dice score

измеряет степень перекрытия между прогнозируемой контрастностью и целевой картой контрастности для заданного процента  $x\%$  наиболее активированных вершин:

$$Dice(x) = \frac{2|Prediction(x) \cap Target(x)|}{|Prediction(x)| + |Target(x)|},$$

- ▶  $|Prediction(x)|$  – количество топ- $x\%$  наиболее активированных вершин на прогнозируемой карте контрастности,
- ▶  $|Target(x)|$  – количество топ- $x\%$  наиболее активированных вершин в контрасте,
- ▶  $|Prediction(x) \cap Target(x)|$  – количество вершин, которые перекрывают прогнозируемую и целевую карты при заданном пороговом значении.

## Функция потерь

Дан минибатч из  $N$  сэмплов:  $B = \{\mathbf{x}_i\}$ .

$\mathbf{x}_i$  - целевое многоконтрастное изображение объекта  $i$ ,

$\hat{\mathbf{x}}_i$  - соответствующее прогнозируемое изображение контраста,

$d(\cdot)$  - функция потерь.

**The reconstructive-contrastive loss (RC loss):**

$$\mathcal{L}_R = \frac{1}{N} \sum_{i=1}^N d(\hat{\mathbf{x}}_i, \mathbf{x}_i), \quad \mathcal{L}_C = \frac{1}{(N^2 - N)/2} \sum_{\substack{\mathbf{x}_j \in B_i, \\ j \neq i}} d(\hat{\mathbf{x}}_i, \mathbf{x}_j),$$

$$\mathcal{L}_{RC} = [\mathcal{L}_R - \alpha]_+ + [\mathcal{L}_R - \mathcal{L}_C + \beta]_+.$$

$\mathcal{L}_R, \alpha$  - потери и отступ (margin) для одного и то же объекта (R loss).

$\mathcal{L}_C, \beta$  - потери и отступ (margin) для разных объектов (C loss).

Условие:  $(\mathcal{L}_C - \mathcal{L}_R) > \beta$ .

# Эксперименты

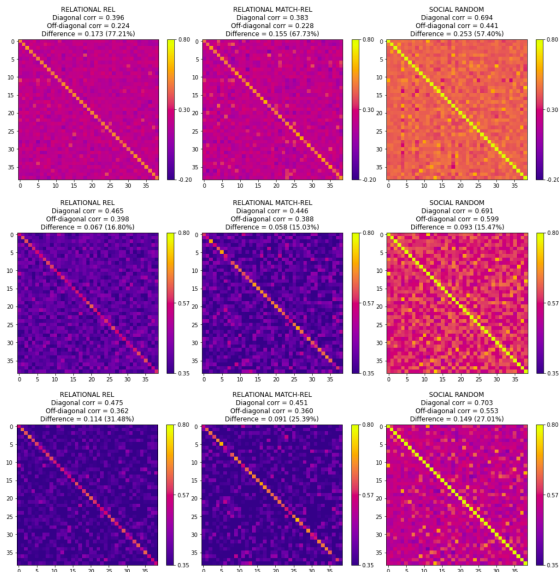
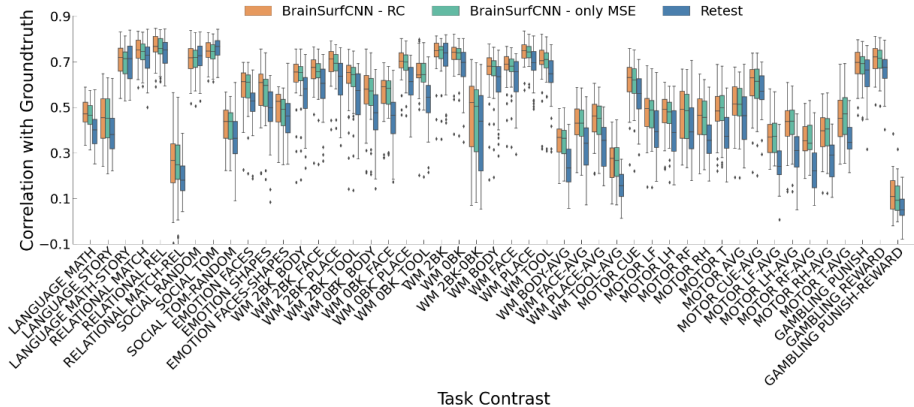
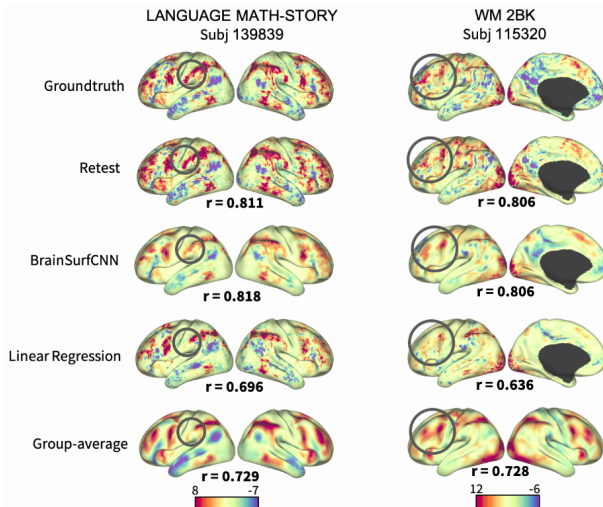


Fig.3. Нормализованные корреляционные матрицы прогнозируемых и истинных контрастов между испытуемыми для трёх заданий и 39 испытуемых



**Fig.4.** Корреляция прогнозируемых и истинных контрастов в 47 индивидуальных заданиях





**Fig.5.** Визуализация поверхности для сравнения двух заданий у 2 испытуемых. В крайнем правом столбце приведены средние значения контрастов по группе для сравнения




Fig.6. Точность прогнозов для индивида в 23 надежно прогнозируемых задачах

# Список литературы

1. Ngo G. H. et al. 2022. [Predicting individual task contrasts from resting-state functional connectivity using a surface-based convolutional network.](#)
2. Bernstein-Eliav M., Tavor I. et al. 202. [The prediction of brain activity from connectivity: advances and applications.](#)
3. Jones O. P. et al. 2017. [Resting connectivity predicts task activation in pre-surgical populations.](#)
4. Tavor I. et al. 201. [Task-free MRI predicts individual differences in brain activity during task performance.](#)
5. Lockett P. H. et al. [Resting state network mapping in individuals using deep learning](#)
6. Pagani M. et al. [Resting state fMRI connectivity mapping across species: Challenges and opportunities](#)
7. Kumar V. A. et al [The role of resting-state functional MRI for clinical preoperative language mapping](#)
8. Hou X. et al. [Deep-learning-enabled brain hemodynamic mapping using resting-state fMRI](#)
9. Rabini G., Ubaldi S., Fairhall S. L. [Task-based activation and resting-state connectivity predict individual differences in semantic capacity for complex semantic knowledge](#)
10. Zheng Y. Q. et al. [Accurate predictions of individual differences in task-evoked brain activity from resting-state fMRI using a sparse ensemble learner](#)
11. Duda M. et al. [Reliability and clinical utility of spatially constrained estimates of intrinsic functional networks from very short fMRI scans](#)
12. Duda M., Iraj A., Calhoun V. D. [Spatially constrained ICA enables robust detection of schizophrenia from very short resting-state fMRI](#)
13. Lin Q. H. et al. [Semiblind spatial ICA of fMRI using spatial constraints](#)
14. Wang Z. et al. [Temporally and spatially constrained ICA of fMRI data analysis](#)
15. Dataset: [Human Connectome Project](#)

# Заключение

- ▶ Были рассмотрены подходы к проблеме исследования функционального картирования мозга
- ▶ Проанализирована литература
- ▶ Намечен план дальнейшего исследования, в частности 2 возможных направления:
  - ▶ Отображение fMRI в состоянии покоя (Resting state fMRI mapping)
  - ▶ Пространственно ограниченный ICA fMRI (Spatially constrained ICA fMRI)
- ▶ Были проведены основные эксперименты и посчитаны метрики
- ▶ Была написана основная часть текста статьи